UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y Sistemas

Práctica 2 - Extracción de características

PRESENTA

Munive Ramírez Ibrahim

PROFESORA

Dra. María Elena Martínez Pérez

ASIGNATURA

Reconocimiento de Patrones

1. Objetivos

Implementar el descriptor **Patrones binarios locales** en el código para extraer características de texturas y clasificarlas utilizando `K-NN`. El proceso incluye:

α_1. Cálculo de mapa de patrones binarios locales.

α_2. Extracción de histogramas de características.

α_3. Clasificación y evaluación de resultados.

2. Introducción

Los histogramas constituyen la base de varias técnicas de procesamiento en el dominio espacial. La manipulación de los histogramas es usada de manera eficiente en el realce o mejoramiento de la calidad de una imagen. La información estadística obtenida a partir de los histogramas se utiliza en diversas aplicaciones como compresión y segmentación de imágenes. La facilidad con la que se pueden calcular los histogramas usando software y su bajo consumo de recursos de hardware en su implementación, han hecho de esta herramienta una de las más usadas en el procesamiento en tiempo real.

El histograma de una imagen es la representación gráfica de la distribución que existe de las distintas tonalidades de grises con relación al número de píxeles o porcentaje de los mismos, es decir, un histograma representa la frecuencia relativa de ocurrencia de los niveles de gris. La representación de un histograma ideal sería la de una recta horizontal, ya que eso nos indicaría que todos los posibles valores de grises están distribuidos de manera uniforme en nuestra imagen.

La ecualización del histograma es una técnica bastante conocida y sirve para obtener un histograma uniforme de tal manera que los niveles de gris son distribuidos sobre la escala y un número igual de píxeles son colocados en cada nivel de gris. Para un observador, esta ecualización hace que las imágenes se vean más balanceadas y con mejor contraste. Como consecuencia, una imagen ecualizada, permite que ciertos detalles sean visibles en regiones oscuras o brillantes.

Un pixel p en las coordenadas (x, y) tiene 4 vecinos horizontales y 4 verticales cuyas coordenadas están dadas por:

$$(x+1, y), (x-1, y), (x, y+1), (x, y-1) \tag{1}$$

Este grupo de píxeles se anota con $N_4(p)$. Así mismo, las vecindades diagonales con el punto (x, y) se anotan como $N_D(p)$ y sus coordenadas son:

$$(x+1, y+1), (x-1, y-1), (x-1, y+1), (x+1, y-1) \tag{2}$$

Para definir de forma adecuada el concepto de vecindad, es necesario revisar el de adyacencia. Dos píxeles son adyacentes si, y sólo si, tienen en común una de sus fronteras, o al menos una de sus esquinas. La figura 1 muestra píxeles adyacentes.

Dos píxeles son vecinos si cumplen con la definición de adyacencia. Si los píxeles comparten una de sus fronteras, se dice que los mismos son vecinos directos; si solo se tocan en una de sus esquinas, se llaman vecinos indirectos.

Una vecindad de un pixel p_0 denota como V_p, es una submatriz M_{KL} de tamaño $K \times L$ con K y L enteros impares pequeños, contenida en la matriz imagen (i_{MN}), la cual está formada por un número finito de pixeles vecinos o no de p_0.

$$V_p = \{p : p \in M_{KL}\}; \quad M_{KL} \subset i_{MN}; \quad K = L = 3, 5, 9 \tag{3}$$

Para ilustrar las definiciones anteriores, se puede observar en la figura 2, vecindades de 4 y de vecindades 8, la primera formada por píxeles que son vecinos directos, mientras que la vecindad de 8 está formada tanto por vecinos directos como indirectos.

En el desarrollo de las técnicas de procesamiento de imágenes que involucren el análisis de una determinada región de la escena digital, es posible encontrar vecindades de 5×5 y hasta 9×9 básicamente la definición de las dimensiones de la matriz vecindad depende de la técnica que se esté desarrollando.

Principio del algoritmo LBP

El algortimo de patrones binarios locales (LBP por sus siglas en ingles Local Binary Pattern) es un algoritmo muy usado en visión por computadora para describir la textura de una imagen. Funciona comparando la intensidad de un píxel con la de sus vecinos y generando un código binario que representa el patrón local. El algoritmo de LBP calcula una puntuación para cada píxel comparándolo con sus vecinos.

Matemáticamente, para un píxel central g_c y P vecinos en un radio R:

$$LBP_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c)2^p \tag{4}$$

Donde $s(x)$ es la función signo:

- $s(x) = 1$ si $x \geq 0$
- $s(x) = 0$ si $x < 0$

Para entender la técnica de LBP, debemos mirar dentro de una ventana de 3×3 píxeles. El algoritmo convierte la textura local en un número entero simple.

Mecánica de Cálculo Manual (Invariante a la Rotación):

1. **Umbralización:** Compara cada uno de los 8 vecinos ($P = 8, R = 1$) con el píxel central. Si el vecino es mayor o igual, se asigna '1'; de lo contrario, '0'.
2. **Ponderación y Suma:** Los bits resultantes se multiplican por potencias de 2 ($2^0, 2^1, ..., 2^7$) siguiendo un orden (por ejemplo, sentido horario comenzando arriba a la izquierda) y se suman para obtener el valor LBP decimal.

3. Desarrollo

3.1. Extracción de Características con LBP para Clasificación de Texturas

1. **Descarga y organiza el conjunto de imágenes:** Puedes utilizar el dataset clásico en análisis de texturas Brodatz Texture Dataset, el conjunto Flickr Material Database (FMD) o un conjunto personalizado de distintas clases:
   - corteza, ladrillo, burbujas, hierba, cuero, piel, rafia, arena, paja, agua, tejido, madera, lana
2. **Carga las imágenes y conviértelas a escala de grises:** El Brodatz Texture Dataset original no incluye etiquetas categóricas. Sin embargo, existen versiones modificadas y extensiones del dataset que sí incluyen etiquetas o puedes asignar etiquetas basadas en la tabla de referencia.
   - Mostrar imagen e histograma de una imagen de cada clase.
3. **Implementación de LBP.** El algoritmo LBP sigue estos pasos:
   a) Para cada píxel central, comparar su intensidad con 8 vecinos.
   b) Generar un patrón binario (1 si el vecino >central, 0 en otro caso).
   c) Convertir el binario a decimal y reemplazar el píxel central.
4. **Extracción de Características:** Convertir cada imagen LBP en un histograma de 256 bins (para valores 0-255).
   a) Mostrar el histograma normalizado de una imagen de cada clase.
   b) Comparar histogramas por clase (ej. madera vs. tela vs. piedra).
5. **Clasificación y Evaluación**
   a) Divide los datos en entrenamiento (70 %) y prueba (30 %).

   b) Usa un modelo simple como vecinos más cercanos (k-NN) o Máquina de Soporte Vectorial (SVM) sobre los vectores de características y entrena el modelo.
   c) Calcula la exactitud en el conjunto de prueba.
   d) Visualiza las imágenes LBP para entender qué patrones se están detectando.
   e) Mostrar matriz de confusión.

6. **Visualización de Resultados:**
   a) Descripción de los pasos realizados.
   b) Resultados obtenidos (gráficos y análisis).

7. Repite los pasos 3, 4, 5 y 6 aplicando el algoritmo LBP con configuraciones como $P = 16, R = 2$ y $P = 24, R = 3$ y compara resultados.

4. Código

5. Conclusiones

6. Referencias

- Gonzalez, R., Woods, R., Digital Image Processing, Prentice Hall, 2008.
- Pratt, W. k., Digital Image Processing, John Wiley and Sons Inc, 2001.
- Jahne, B., Digital Image Processing, Springer, 2005.
- Sánchez Garreta, Josep Salvador; García, Vicente. Special Issue on Data Preprocessing in Pattern Recognition: Recent Progress, Trends and Applications. 2022.