UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y Sistemas

Práctica 3 - Selección de Características

PRESENTA

Munive Ramírez Ibrahim

PROFESORA

Dra. María Elena Martínez Pérez

ASIGNATURA

Reconocimiento de Patrones

1. Objetivos

- Implementar diferentes métodos de selección de características
- Comparar resultados entre distintos métodos de selección de características.
- Analizar el impacto de la reducción dimensional.

2. Introducción

La selección de características es fundamental en el campo del reconocimiento de patrones y el aprendizaje automático. Su propósito radica en identificar las variables o atributos más informativos dentro de un conjunto de datos, descartando aquellos que son redundantes, irrelevantes o ruidosos. Este proceso no solo mejora la eficiencia computacional, sino que también eleva la capacidad de generalización de los modelos, permitiéndoles identificar patrones subyacentes evitando el sobreajuste (overfitting). Este proceso, que consiste en identificar el equilibrio entre la simplificación y la optimización, trabajar con menos datos, pero de mayor calidad.

2.1. La Importancia de la Selección de Características

En problemas de alta dimensionalidad, donde el número de características puede superar ampliamente la cantidad de muestras, la selección de estás características se vuelve crítica. Por ejemplo, en imágenes médicas o datos genómicos, es común tener miles de variables, muchas de las cuales pueden ser correlacionadas o carecer de valor predictivo. Al reducir la dimensionalidad, los algoritmos evitan considerar información irrelevante, enfocándose en los atributos clave que definen los patrones. Además, modelos más simples son más interpretables, un aspecto que sobresale en áreas como la medicina o las ciencias sociales, donde entender por qué un modelo toma una decisión es tan importante como su precisión.

2.2. Desafíos y Consideraciones Prácticas

La selección de características continúa teniendo muchos retos. Uno de los más significativos es el manejo de relaciones no lineales o complejas entre variables. Por ejemplo, en problemas de visión artificial, la textura de una imagen puede depender de la interacción no aditiva entre píxeles vecinos, algo que métodos lineales como la correlación podrían pasar por alto. Pero técnicas basadas en métodos no paramétricos (como el análisis de componentes independientes) pueden ser más apropiadas.

Otro desafío es la estabilidad, en donde un conjuntos de datos con alto nivel de ruido o muestras

limitadas, pueden variar significativamente los subconjuntos seleccionados entre particiones de entrenamiento y validación. Esto afecta a la confiabilidad del modelo, especialmente en aplicaciones críticas como el diagnóstico médico. Para mitigarlo, se recomienda usar técnicas de validación cruzada robustas o métodos de consenso. Adicionalmente, es crucial evitar un enfoque limitado que priorice características individualmente relevantes pero descarte grupos complementarios. Como puede ser el caso del procesamiento de lenguaje natural (NLP), palabras como *no* o *nunca* pueden parecer irrelevantes en un análisis univariado, pero son esenciales para entender el sentimiento negativo cuando se combinan con otros términos.

3. Desarrollo

3.1. Selección de Características

Utiliza alguno de los conuntos de datos propuestos:

Arritmia. (*Arrhythmia Database UCI Machine Learning Repository*), el objetivo de este conjunto de datos es diferenciar entre arritmias cardíacas y clasificarlas en uno de los 16 grupos. La clase 01 agrupa a las señales de electrocardiograma (ECG) 'normales', del 02 al 15 a diferentes clases de arritmias y la clase 16 al resto de las señales ECG de arritmias no clasificadas. Cuenta con 452 muestras, 279 características, 206 de las cuales son de valores cuantitativos y el resto cualitativos.

Expresión genética en pacientes con leucemia (*Gene expression dataset from Golub et al.* (1999)), este conjunto de datos consta de 47 pacientes con leucemia linfoblástica aguda (LLA) y 25 pacientes con leucemia mieloide aguda (LMA). A cada uno de los 72 pacientes se le extrajeron muestras de médula ósea al momento del diagnóstico, las mediciones de expresión génica de las muestras resultaron en 7129 características que representan los niveles de expresión de genes para cada muestra. Este conjunto de datos tiene una alta dimensión con pocas muestras, valores con ruido y posible desbalance de clases.

1. Verificar la integridad del conjunto de datos desde valores faltantes, clases minoritarias con muy pocas muestras, datos atípicos y escalas de datos diferentes (algunas características son frecuencias, otras voltajes).
2. Preparación de Datos
   a) Detectar valores faltantes y completarlos si es el caso.
   b) Aplicar escaladores para remover o mitigar el efecto de muestras atípicas (por ejemplo z-score).
   c) Aplicar técnicas para corregir desbalanceos (como sobremuestreo de la clase minoritaria).

d) Implementar validación cruzada para evaluar cada método de selección manteniendo un conjunto de prueba separado.

e) Dividir los datos (80 % entrenamiento / 20 % prueba) sin incluir los datos de prueba en la optimización de parámetros.

3. Implementación de Métodos

   a) **Búsqueda Secuencial hacia delante (SFS)**
      - SFS con validación cruzada e interrupción temprana (*early stopping*) si la exactitud no mejora en 3 iteraciones.
      - Generar gráfico exactitud por características (20 mejores características).

   b) **Fisher**
      - Implementar función del cálculo Score de separabilidad entre clases.
      - Calcular puntuaciones de relevancia de cada característica.
      - Selecciona las 20 características con mayor puntuación.

   c) **PCA**
      - Remover pares de características altamente correlacionadas (coeficiente > 0.9).
      - Determinar componentes para 95 % varianza.
      - Visualizar proyección 2D.

4. Análisis de resultados

   a) ¿Qué método obtuvo mejor exactitud? ¿Por qué?.

   b) ¿Qué método es más robusto ante outliers y desbalanceo?

   c) ¿Cómo afecta la correlación entre características al PCA?.

   d) ¿Qué ventajas tiene Fisher Score sobre SFS en términos computacionales?.

4. Código

4.1. Repositorio

El notebook `.ipynb` así como los demás archivos de la práctica se encuentran en el siguiente repositorio de GitHub: https://github.com/Garp02/Reconocimiento-Patrones/tree/main/P3

4.2. Conjunto de datos y reformulación del problema

Se trabajó con el conjunto **Arrhythmia** del *UCI Machine Learning Repository*, que contiene 452 registros y 279 características derivadas de electrocardiogramas (ECG) más una etiqueta de clase. La clase original distingue entre 16 categorías (normal, 14 tipos de arritmia y una clase residual). Al inspeccionar su distribución se observó que varias clases contienen apenas 2 a 5 muestras, lo que hace inviable un planteamiento multiclase con validación robusta.

Por esta razón se reformuló el problema como una clasificación **binaria**: clase 1 (normal) frente al resto (arritmia). La proporción resultante es de 245 frente a 207 registros, prácticamente balanceada (ratio 0,542), por lo que no fue necesario aplicar técnicas de sobremuestreo como SMOTE. La Figura 1 muestra ambas distribuciones.

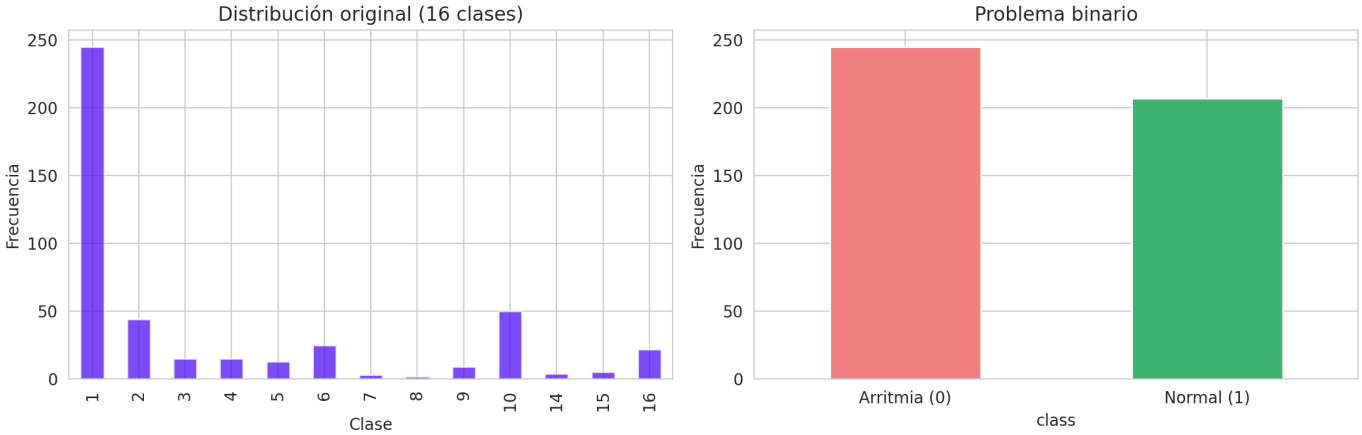

Figura 1: Distribución de clases original (izquierda) y reformulación binaria (derecha).

4.3. Perfilamiento exploratorio con `ydata_profiling`

Como primer diagnóstico se ejecutó `ydata_profiling` sobre las 15 primeras columnas (las documentadas en `arrhythmia.names`: edad, sexo, medidas antropométricas, duraciones e intervalos del complejo QRS, ángulos eléctricos y frecuencia cardíaca). Se eligió este subconjunto porque son las únicas variables con interpretación clínica directa; las restantes 264 corresponden a mediciones derivadas por derivación del ECG cuyo significado queda implícito.

El reporte general indica las siguientes estadísticas globales:

- **Dimensiones**: 452 observaciones, 15 variables (14 numéricas y 1 categórica, `sex`).
- **Celdas faltantes**: 408 en total, equivalente al 6,0 % del conjunto, concentradas en sólo tres variables.

- **Duplicados**: 0 filas duplicadas.
- **Tamaño en memoria**: 53.1 KiB, $\approx$ 120 bytes por registro.

El informe levantó doce alertas automáticas, agrupables en tres categorías:

- **Valores faltantes.** Tres variables presentan huecos: `j_angle` con 376 (83.2 %), `p_angle` con 22 (4.9 %) y `t_angle` con 8 (1.8 %). La saturación de `j_angle` hace inviable su imputación sin introducir sesgo artificial, por lo que se descartó de forma íntegra. Las otras dos, junto con los `NaN` aislados de `qrst_angle` y `heart_rate`, se imputaron con la mediana de la columna en el conjunto de entrenamiento.
- **Correlaciones altas.** El reporte identificó tres pares de variables con correlación global fuerte: `heart_rate`↔`qt_interval`, `p_interval`↔`pr_interval` y `qrs_angle`↔`qrst_angle`. Todas tienen justificación fisiológica: la frecuencia cardíaca acorta proporcionalmente el intervalo QT, el intervalo PR engloba al intervalo P, y el ángulo QRST se construye a partir del ángulo QRS. Este hallazgo es consistente con lo que después se observó a escala completa: al aplicar el filtro de $|\rho| > 0{,}9$ sobre las 261 características usables se detectaron 24 pares redundantes adicionales.
- **Ceros estructurales.** `pr_interval` (18 ceros, 4.0 %), `p_interval` (12 ceros, 2.7 %) y `qrst_angle` (6 ceros, 1.3 %). En el contexto clínico, un intervalo PR de cero milisegundos no es un valor físico sino un código para "no medible", típicamente asociado a señales donde la onda P está ausente o ilegible. Aunque el dataset no documenta explícitamente esta convención, se decidió tratarlos como valores válidos para no restar muestras; su efecto se mitiga posteriormente con el escalado *z-score*.

Adicionalmente se revisaron los rangos de las variables numéricas para confirmar el problema de escalas heterogéneas: las duraciones (QRS, PR, QT, T) se miden en milisegundos y rondan valores de 80 a 400; los ángulos vectoriales oscilan entre $-180°$ y $+180°$; el peso, la altura y la edad se expresan en sus unidades naturales; y las 264 características derivadas del ECG (no incluidas en el perfilamiento) mezclan amplitudes en milivoltios con ángulos y duraciones. Esta diversidad refuerza la necesidad de estandarizar antes de aplicar métodos sensibles a la escala como PCA y SVM.

4.4. Preparación de los datos

El flujo de preparación aplicado, en este orden, fue el siguiente:

1. **Descartar** la columna `j_angle` por su proporción de `NaN` cercana al 83 %.
2. **Eliminar** 17 columnas constantes (varianza cero), que no aportan información discriminativa.

3. **Dividir** los datos de forma estratificada en 80 %/20 % ($n_{train} = 361$, $n_{test} = 91$). El conjunto de prueba se reservó intacto durante toda la experimentación.
4. **Imputar** los valores faltantes con la mediana, ajustando el imputador solo sobre *train*.
5. **Escalar** con *z-score*, nuevamente ajustando media y desviación solo en *train* y aplicando la transformación a *test*.

Tras estos pasos se conservan **261 características**. El orden importa: la partición se realiza antes de imputar y escalar para impedir que información de *test* contamine la estimación de medianas y varianzas.

4.5. Implementación de los métodos

Como clasificador base para todas las evaluaciones se empleó un **SVM lineal** (`LinearSVC`, $C = 1{,}0$). La validación cruzada fue 5-fold estratificada. El baseline con las 261 características originales alcanzó una exactitud en CV de $0{,}6731 \pm 0{,}0452$.

Búsqueda Secuencial hacia delante (SFS)

El método se aplicó de dos formas, con el fin de comparar una implementación desde cero contra la de una biblioteca estándar:

- **SFS manual**. Partiendo del conjunto vacío, en cada iteración se añade la característica que más eleva la exactitud en CV. Se aplicó *early stopping* con paciencia de 3 iteraciones sin mejora. Este criterio equivale al descrito en el enunciado.
- **SFS de `scikit-learn`**. Se utilizó el estimador `SequentialFeatureSelector` con `n_features_to_select = .ªuto"` y `tol =` 10^{-3}. El parámetro `tol` implementa un *early stopping* distinto: se detiene cuando la mejora entre dos iteraciones consecutivas es menor a ese umbral. A diferencia del criterio de paciencia, esta variante se detiene a la primera iteración estancada y por tanto es algo más conservadora.

La versión manual se detuvo en la iteración 12 tras tres iteraciones sin mejora, quedándose con las **9 primeras características** y una exactitud en CV de **0,7782**. La versión de `sklearn` concluyó con **7 características** y una exactitud en CV de **0,7755**. La Figura 2 sobrepone ambos resultados: la curva corresponde a la traza iteración a iteración de la versión manual (único método que expone el historial), mientras que el punto azul marca el resultado final de `sklearn`.

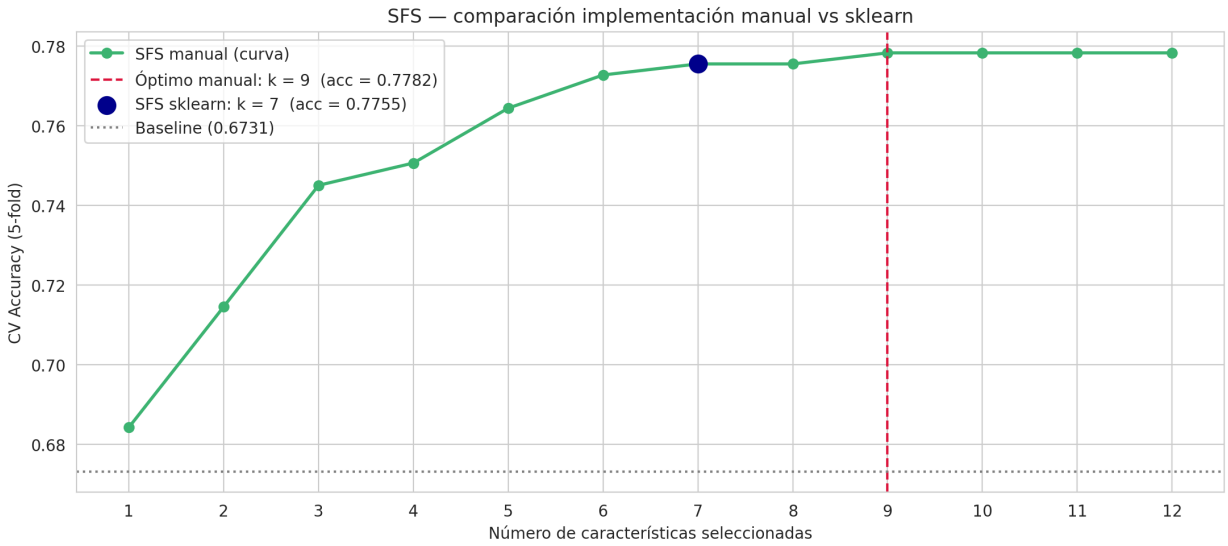

Figura 2: SFS con *early stopping*: curva de aprendizaje de la implementación manual y comparación con el resultado de `SequentialFeatureSelector` de `scikit-learn`.

Las 9 características seleccionadas por la versión manual son: `qrs_duration`, `a_169`, `a_103`, `a_114`, `a_250`, `a_61`, `a_44`, `height` y `a_73`. Las 7 elegidas por `sklearn` son: `qrs_duration`, `a_44`, `a_61`, `a_103`, `a_114`, `a_169` y `a_250`. La coincidencia es total: las 7 de `sklearn` son exactamente un subconjunto de las 9 del método manual, lo que refuerza la estabilidad del núcleo discriminativo. Las dos características adicionales (`height` y `a_73`) aportan mejoras marginales que el criterio de `sklearn` (sin paciencia) no considera suficientes.

Fisher Score

Para un problema con C clases, la puntuación de Fisher de la característica j se define como

$$F_j = \frac{\sum_{c=1}^{C} n_c \, (\mu_j^{(c)} - \mu_j)^2}{\sum_{c=1}^{C} n_c \, (\sigma_j^{(c)})^2}, \tag{1}$$

donde μ_j es la media global de la característica, $\mu_j^{(c)}$ y $\sigma_j^{(c)}$ la media y desviación estándar dentro de la clase c, y n_c el número de muestras de esa clase. El numerador mide la varianza *entre clases* y el denominador la varianza *intra-clase*. Valores altos indican mayor separabilidad.

Los 20 atributos con mayor puntuación de Fisher se muestran en la Figura 3. La característica más discriminativa es `qrs_duration` ($F \approx 0{,}14$), coincidente con la primera elegida por ambas versiones de SFS. La curva de la Figura 4 indica cómo varía la exactitud al usar los k mejores atributos.

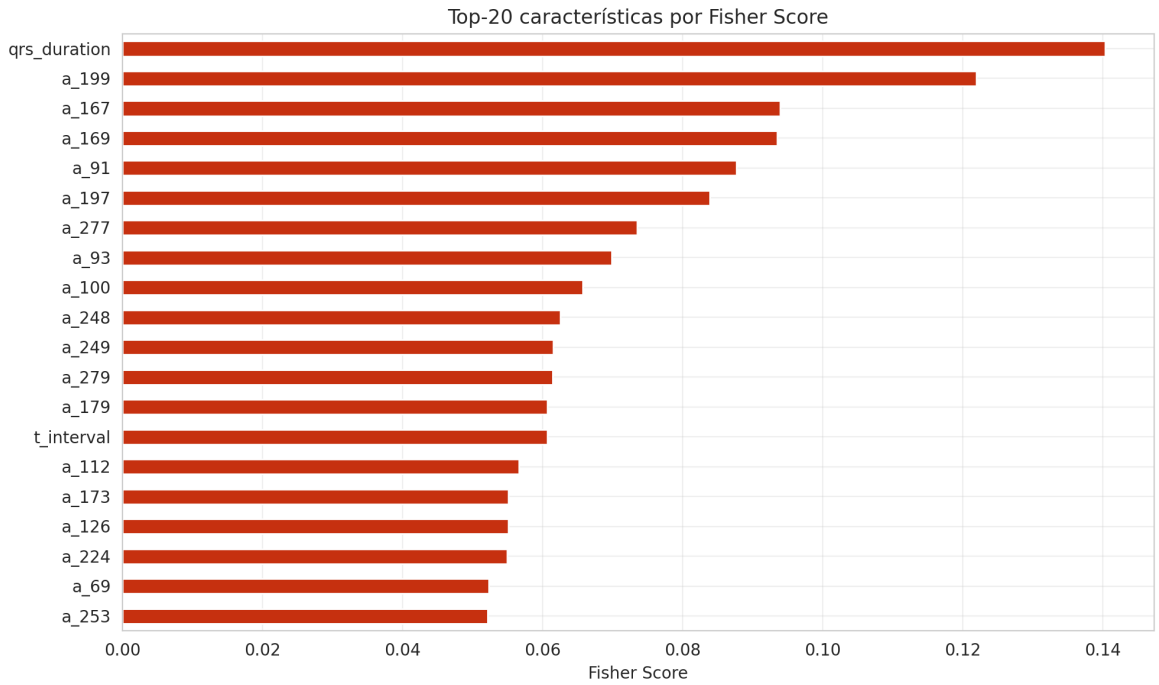

Figura 3: 20 características con mayor Fisher Score.

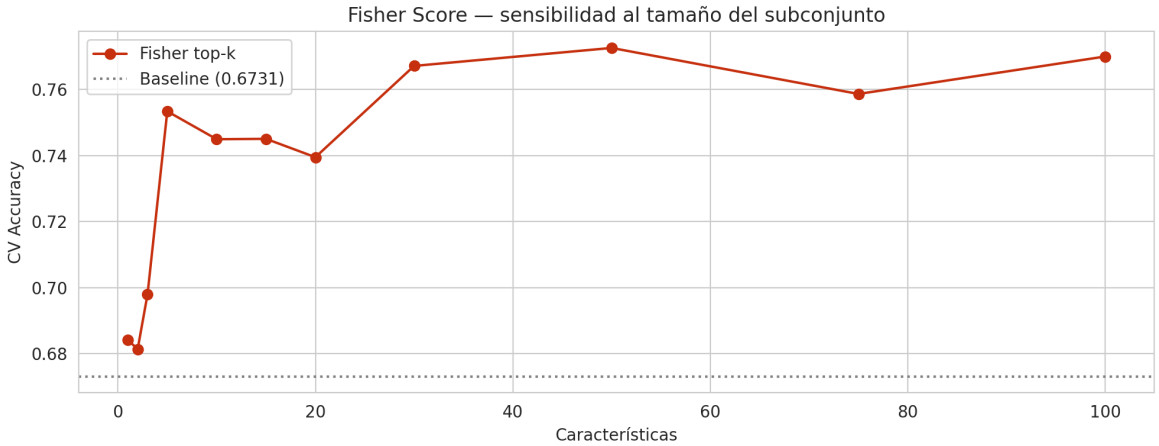

Figura 4: Exactitud en CV en función del número de características top-k seleccionadas por Fisher Score.

Usando las 20 mejores, la exactitud de CV fue $0{,}7395 \pm 0{,}0393$.

Análisis de Componentes Principales (PCA)

Antes de aplicar PCA se eliminaron los pares de características con correlación absoluta $|\rho| > 0{,}9$: esto removió 24 columnas, dejando 237 para el análisis. Este paso es esencial porque PCA asume que la varianza es proxy de información, y variables redundantes inflan artificialmente los primeros componentes. El perfilamiento previo ya había anticipado este problema al detectar pares altamente correlacionados entre las 15 variables clínicas; al extender el análisis a las 261 columnas el número de pares redundantes crece considerablemente.

La Figura 5 muestra la varianza acumulada. Son necesarias **94 componentes** para alcanzar el 95 %, lo que implica que, pese a las 237 características de entrada, la información efectiva ocupa aproximadamente ese número de dimensiones independientes. Con 94 componentes la exactitud de CV fue $0{,}6949 \pm 0{,}0841$.

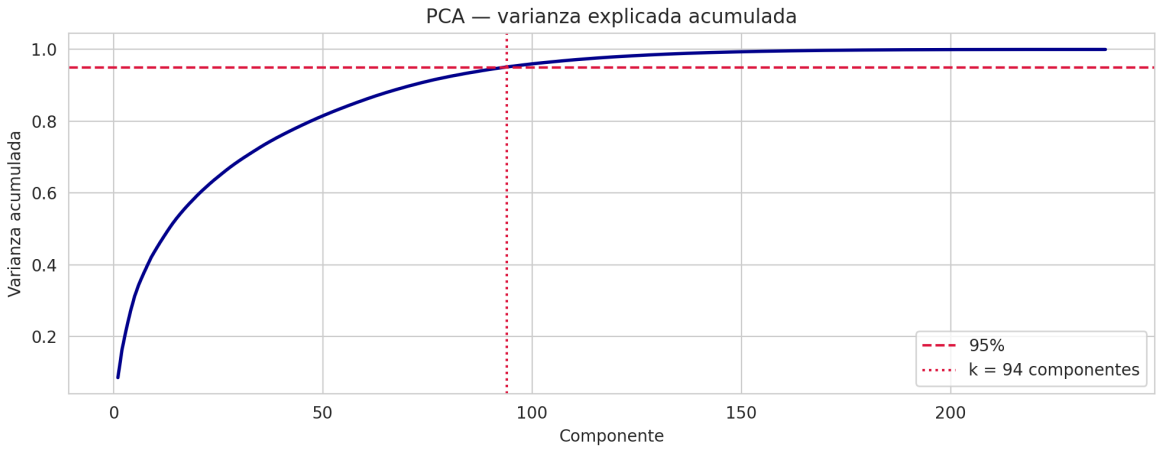

Figura 5: Varianza explicada acumulada por PCA. Se requieren 94 componentes para superar el umbral del 95 %.

La proyección sobre las dos primeras componentes (Figura 6) evidencia visualmente la dificultad del problema: ambas clases se superponen extensamente en el plano PC1–PC2, que explica apenas un $\sim 20\,\%$ de la varianza total. La falta de separación es esperable porque PCA maximiza varianza, no discriminabilidad; las direcciones que más separan normal de arritmia no tienen por qué coincidir con las de mayor varianza.

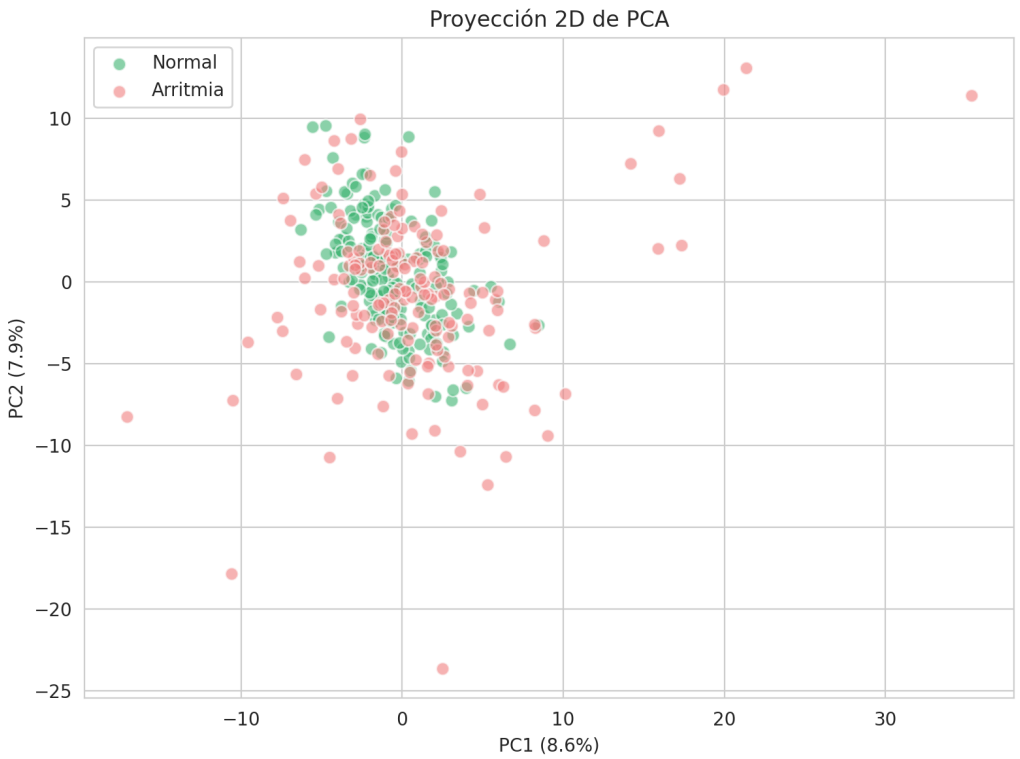

Figura 6: Proyección 2D de los datos de entrenamiento sobre las dos primeras componentes principales.

4.6. Comparación final sobre el conjunto de prueba

Con el subconjunto fijado por cada método se entrenó un SVM lineal sobre el conjunto de entrenamiento completo y se evaluó sobre el 20 % de prueba, intocado durante todo el proceso. La Tabla 1 resume los resultados y la Figura 7 presenta las matrices de confusión.

Método	Nº feats	CV Accuracy	Test Accuracy	Test AUC
Baseline (todas)	261	0,6731	0,6484	0,6905
SFS manual	9	**0,7782**	0,7143	0,7590
SFS `sklearn`	**7**	0,7755	0,7143	0,7585
Fisher Score	20	0,7395	**0,7582**	**0,7638**
PCA (95 % var)	94	0,6949	0,6703	0,6424

Cuadro 1: Comparativa de los métodos de selección de características.

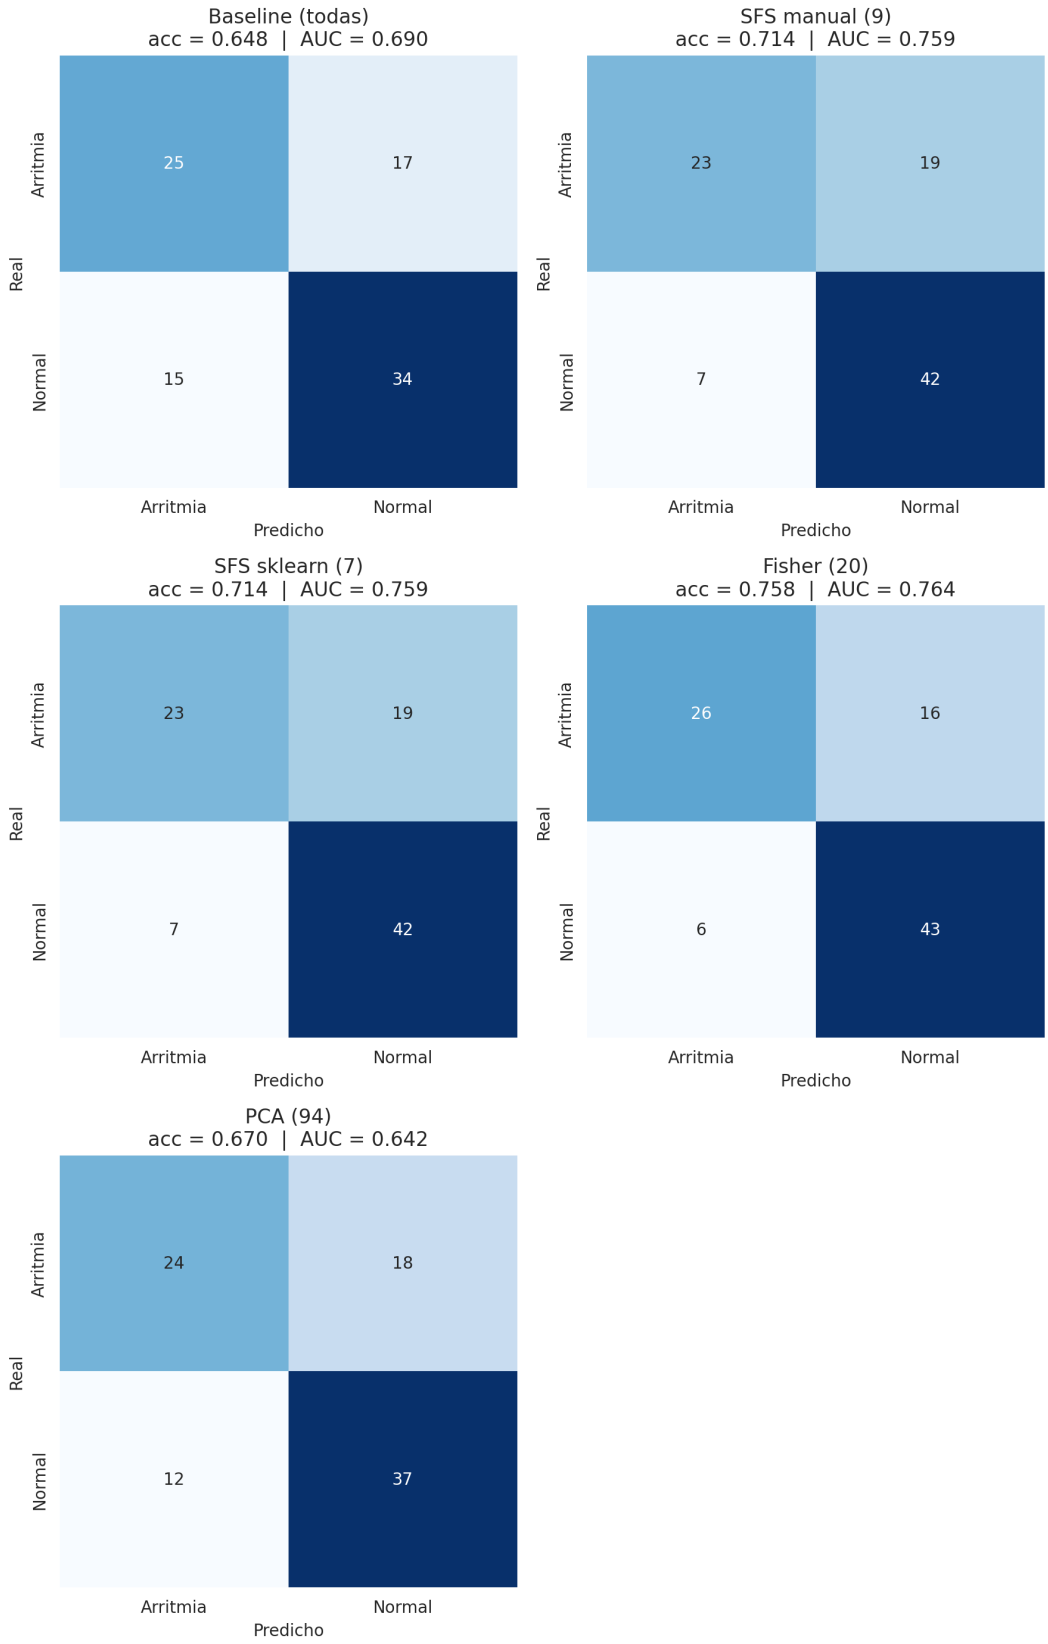

Figura 7: Matrices de confusión sobre el conjunto de prueba para cada método.

La intersección de las tres selecciones supervisadas (SFS manual, SFS `sklearn` y Fisher Score) contiene exactamente `qrs_duration` y `a_169`: son las dos candidatas que los tres métodos coinciden en identificar como discriminantes. `qrs_duration` encabeza además el ranking de Fisher y es la primera elegida por ambas versiones de SFS, confirmando su papel central. Entre SFS manual y `sklearn` la coincidencia es incluso mayor, con las 7 features de `sklearn` contenidas íntegramente en las 9 del manual.

4.7. Análisis de resultados

(a) ¿Qué método obtuvo mejor exactitud? ¿Por qué?

La respuesta depende de la métrica y del conjunto donde se mida:

- En **validación cruzada**, las dos versiones de SFS fueron superiores (manual 0,7782, `sklearn` 0,7755), seguidas por Fisher (0,7395) y PCA (0,6949). Es el resultado esperado: SFS es un método *wrapper* que optimiza directamente la métrica del clasificador final y captura interacciones entre variables.
- En **prueba**, sin embargo, **Fisher Score** obtuvo la mejor exactitud (0,7582) y la mejor AUC (0,7638), mientras que ambas versiones de SFS quedaron ligeramente por debajo (0,7143 en exactitud). La diferencia entre CV y test —de 0,778 a 0,714 en SFS manual— es un caso clásico de *selection bias*: al buscar exhaustivamente en el espacio de subconjuntos usando la misma CV, el método sobreajusta y el optimismo no se traslada al conjunto de prueba. Fisher, al ser un filtro que no optimiza la métrica del clasificador, es menos vulnerable a ese sesgo.

Un punto metodológico importante: el tamaño del conjunto de prueba es de apenas 91 muestras, por lo que una diferencia de 4 puntos porcentuales está dentro del ruido muestral. Los AUC de los tres métodos supervisados (0,7585–0,7638) son prácticamente indistinguibles. Concluir que Fisher "gana" de forma categórica sería precipitado; lo honesto es decir que los tres métodos son equivalentes en generalización y que SFS paga su mejor ajuste en CV con una ligera pérdida en test.

(b) ¿Qué método es más robusto ante outliers y desbalanceo?

Fisher Score es el más robusto frente al desbalanceo porque pondera explícitamente por n_c (véase la ecuación 1) y trabaja con estadísticos por clase, no con una métrica global que pueda sesgarse hacia la clase mayoritaria. SFS con exactitud como criterio es el más vulnerable: si una clase domina, la métrica puede recompensar predicciones triviales.

Frente a *outliers*, ninguno de los tres es intrínsecamente robusto: tanto Fisher como PCA dependen de medias y varianzas, que son sensibles a valores extremos. El escalado *z-score* aplicado previamente

limita la escala de los outliers, pero para robustez genuina convendría usar variantes basadas en mediana/MAD o PCA robusto.

(c) ¿Cómo afecta la correlación entre características al PCA?

PCA identifica las direcciones de máxima varianza. Cuando dos o más variables están fuertemente correlacionadas representan esencialmente la misma dirección en el espacio de características, pero su varianza se acumula en ese eje, haciéndolo parecer más relevante de lo que efectivamente es. En consecuencia, los primeros componentes capturan información redundante en vez de independiente, degradando la capacidad del método para comprimir el dataset.

En este trabajo el perfilamiento exploratorio ya alertó sobre pares fisiológicamente redundantes como `heart_rate`–`qt_interval` o `qrs_angle`–`qrst_angle`, que son un caso claro del problema: miden fenómenos relacionados por construcción. Al extender el filtro $|\rho| > 0{,}9$ sobre las 261 columnas se eliminaron 24 antes de aplicar PCA. Sin ese filtro, se habrían necesitado más componentes para llegar al 95 % de varianza, pues los primeros componentes estarían dominados por bloques de variables casi duplicadas.

(d) ¿Qué ventajas tiene Fisher Score sobre SFS en términos computacionales?

La diferencia es de varios órdenes de magnitud. Fisher Score tiene complejidad $\mathcal{O}(n \cdot d)$: un solo recorrido de los datos calculando medias y varianzas por clase, enteramente vectorizable. SFS, en cambio, es $\mathcal{O}(d^2 \cdot k_{cv} \cdot t_{fit})$: en cada una de sus iteraciones entrena el clasificador una vez por cada característica candidata restante, con validación cruzada completa.

En esta práctica, SFS —tanto la versión manual como la de `sklearn`— necesitó entrenar del orden de 15,000 modelos SVM, tardando alrededor de un minuto en un equipo moderno; Fisher se calculó en milisegundos. Esta diferencia explica por qué Fisher y sus parientes (*mutual information*, F-ANOVA, χ^2) son el estándar en problemas de ultra-alta dimensionalidad como los de genómica (p. ej. el dataset de Golub con 7129 genes), donde SFS sería directamente inviable sin paralelización agresiva o recorte previo del espacio de búsqueda.

El hecho de que, en este dataset concreto, Fisher no sólo sea mucho más rápido sino que además generalice mejor al conjunto de prueba que SFS ilustra que la ventaja computacional no siempre va aparejada a una pérdida de calidad. Una estrategia pragmática sería usar Fisher como filtro inicial y SFS únicamente sobre el subconjunto resultante cuando la dimensionalidad original sea prohibitiva.

5. Conclusiones

Comparando distintos enfoques de selección y reducción de dimensionalidad sobre de clasificación médica, se lograron contrastar sus principios teóricos con su desempeño práctico.

La distribución original de 16 clases incluye categorías con muestras de 2 a 5, lo cual impide una validación significativa. Así, mediante la reformulación binaria, casi se balancearon los casos. Y de esta manera no se necesitó aplicar alguna técnica de sobremuestreo o remuestreo.

En validación cruzada, SFS fue superior (0,778), pero en prueba Fisher obtuvo la mejor exactitud (0,758) y AUC (0,764).

El **Fisher Score** ofreció un ranking coherente con SFS en su característica más importante (`qrs_duration`).

Por otro lado, **PCA** no selecciona variables originales, las recombina. La proyección 2D mostró que las direcciones de máxima varianza no coinciden con las que discriminan las clases, es decir tiene desempeño predictivo.

La diferencia observada entre la exactitud en validación cruzada y la exactitud en prueba (especialmente en SFS, 0,778 vs 0,714) se debe a la poca variabilidad de las muestras pequeñas, por ejemplo, $n = 91$.

Finalmente, la eliminación de columnas constantes, imputación, escalado *z-score* y eliminación de correlaciones para PCA tuvo un impacto comparable al de la elección del método de selección. Ningún algoritmo compensa datos mal preparados, y en problemas médicos como este la calidad inicial es tan determinante como el modelo final.

■

6. Referencias

- Gonzalez, R., Woods, R., Digital Image Processing, Prentice Hall, 2008.
- Pratt, W. k., Digital Image Processing, John Wiley and Sons Inc, 2001.
- Jahne, B., Digital Image Processing, Springer, 2005.
- Sánchez Garreta, Josep Salvador; García, Vicente. Special Issue on Data Preprocessing in Pattern Recognition: Recent Progress, Trends and Applications. 2022.
- Guvenir, H., Acar, B., Muderrisoglu, H., & Quinlan, R. (1997). Arrhythmia. UCI Machine Learning Repository. https://doi.org/10.24432/C5BS32.
- Golub TR, Slonim DK, Tamayo P, Huard C, Gaasenbeek M, Mesirov JP, Coller H, Loh ML, Downing JR, Caligiuri MA, Bloomfield CD, and Lander ES (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. Science, 286:531-537.