



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y
Sistemas

Práctica 4 - Clasificadores

PRESENTA

Munive Ramírez Ibrahim

PROFESORA

Dra. María Elena Martínez Pérez

AYUDANTE

M. en C. Miguel Ángel Veloz Lucas

ASIGNATURA

Reconocimiento de Patrones

1. Objetivos

En esta práctica avanzaremos en el uso de cuatro clasificadores supervisados sobre distintos conjuntos de datos. Cada ejercicio incluye:

- Preprocesamiento de datos.
- Reducción de dimensionalidad por PCA y visualización en 2D/3D.
- Búsqueda e interpretación de hiperparámetros.
- Análisis de resultados.

2. Introducción

2.1. Tipos de Clasificadores para Reconocimiento de Patrones

El reconocimiento de patrones es una disciplina fundamental en inteligencia artificial y aprendizaje automático, cuyo objetivo es identificar regularidades o estructuras en datos para asignarles categorías. Los clasificadores son algoritmos que implementan esta tarea, y su elección depende de factores como la naturaleza de los datos, la complejidad del problema y la necesidad de interpretabilidad. A continuación, se describen los principales tipos de clasificadores y sus características, con énfasis en los tres utilizados en esta práctica: k -vecinos más cercanos, árboles de decisión y máquinas de soporte vectorial.

2.2. Clasificadores No Lineales

Cuando los datos presentan relaciones complejas, se emplean modelos no lineales. Los **árboles de decisión** son un ejemplo: dividen recursivamente el espacio de características mediante reglas jerárquicas, lo que los hace altamente interpretables pero propensos al sobreajuste cuando crecen sin control. Sus principales hiperparámetros (profundidad máxima, muestras mínimas por nodo, criterio de división) actúan precisamente como mecanismos de regularización. Otro enfoque es el algoritmo de **k -vecinos más cercanos (KNN)**, que clasifica instancias según la mayoría de clases entre sus vecinos más cercanos en el espacio de características. Aunque es flexible y no requiere entrenamiento explícito —se trata de un método *lazy* o perezoso—, su costo computacional crece con el tamaño de los datos y depende fuertemente del escalado y de la métrica de distancia elegida. Estos métodos son útiles en reconocimiento de escritura manual, sistemas de recomendación o, como en esta práctica, en problemas biomédicos con variables heterogéneas.

2.3. Clasificadores Probabilísticos

Basados en teoría de probabilidad, estos modelos estiman distribuciones para predecir clases. El clasificador **Naïve Bayes** es el más conocido: asume independencia entre características y aplica el teorema de Bayes para calcular probabilidades posteriores. Aunque simplista, es eficaz en datos categóricos o textuales, como en análisis de sentimientos o detección de spam. Las redes Bayesianas, por otro lado, modelan dependencias entre variables, ofreciendo mayor flexibilidad a costa de complejidad.

2.4. Máquinas de Soporte Vectorial (SVM)

Las SVM buscan hiperplanos óptimos para separar clases, incluso en espacios de alta dimensión. En su versión *lineal*, maximizan el margen entre las clases y son particularmente efectivas cuando los datos son linealmente separables o aproximadamente lineales tras un buen escalado. Con *kernels* (típicamente el gaussiano o RBF) transforman implícitamente los datos a espacios de mayor dimensión donde la separación no lineal es posible. Su comportamiento se controla principalmente con dos hiperparámetros: el parámetro de regularización C —que pondera el compromiso entre maximizar el margen y tolerar errores de clasificación— y, en el caso del kernel RBF, el parámetro γ , que define la amplitud de influencia de cada muestra. Son eficaces en reconocimiento facial o clasificación de imágenes médicas, pero requieren ajuste cuidadoso de parámetros y normalización previa de los datos.

2.5. Redes Neuronales

Estos modelos, inspirados en el cerebro humano, destacan por su capacidad para aprender patrones complejos. Los perceptrones multicapa (MLP) son redes *feed-forward* con capas ocultas no lineales, mientras que las redes convolucionales (CNN) se especializan en datos *grid-like* como imágenes. Las redes recurrentes (RNN) manejan secuencias (texto, series temporales). Aunque son extremadamente poderosas (p. ej. en visión por computadora o traducción automática), requieren grandes volúmenes de datos, recursos computacionales y carecen de interpretabilidad directa.

2.6. La Búsqueda en Cuadrícula como Estrategia de Ajuste

Cada uno de los clasificadores anteriores expone un conjunto de hiperparámetros cuya elección puede cambiar significativamente el desempeño. La búsqueda en cuadrícula (*grid search*) es la estrategia más sistemática para explorar este espacio: se define una lista de valores plausibles para cada hiperparámetro y se entrena el modelo para todas las combinaciones, evaluando cada una mediante validación cruzada. Aunque es exhaustiva —y por tanto costosa cuando el número de combinaciones crece—, garantiza encontrar el óptimo dentro de la cuadrícula definida y ofrece una visión clara de qué hiperparámetros realmente importan.

3. Desarrollo

3.1. Aplicación y comparación de clasificadores

Selecciona conjuntos de datos para entrenar distintos modelos de clasificación variando la configuración de sus hiperparámetros.

Conjuntos de datos propuestos:

- **Clasificación Multimodelo para Cáncer de Mama** (*Breast Cancer Wisconsin Diagnostic*): conjunto de datos biomédicos que contiene características numéricas derivadas de imágenes digitales de aspiraciones con aguja fina (FNA) de masas mamarias, utilizadas para clasificar tumores como benignos o malignos.
- **Detección Temprana de Parkinson, voz y biomarcadores acústicos** (*Parkinsons Telemonitoring*): conjunto diseñado para apoyar la investigación en el diagnóstico de la enfermedad de Parkinson. Contiene medidas biomédicas de voz obtenidas de personas sanas y pacientes con la enfermedad, con el objetivo de diferenciar ambos grupos mediante técnicas de aprendizaje automático.
- **Clasificación de Cardiopatía** (*Heart Disease*): recopila información de pacientes para determinar la probabilidad de enfermedad cardíaca, codificada en una variable objetivo que indica la presencia o ausencia de la condición. Entre las variables predictoras se incluyen edad, sexo, presión arterial en reposo, nivel de colesterol, frecuencia cardíaca máxima y resultados de pruebas electrocardiográficas.
- **Verificador de síntomas de COVID-19** (*COVID Symptom Classification Dataset*): los datos identifican si una persona padece o no la enfermedad del coronavirus, basándose en algunos síntomas estándar predefinidos. Dichos síntomas se basan en las directrices de la OMS y del Ministerio de Salud y Bienestar Familiar de la India.

1. Carga y análisis de datos:

- a) Cargar el conjunto de datos.
- b) Visualización de la distribución de clases.
- c) Análisis de valores faltantes (porcentaje por columna).

2. Preprocesamiento y limpieza:

- a) Separación de tipos de variables (columnas numéricas y categóricas).
- b) Verificar y aplicar limpieza de datos (faltantes, *outliers*, caracteres inválidos, etc.).
- c) Estandarización de características (escaladores).

- d) Separación en 70 % entrenamiento y 30 % prueba.
- e) Manejo del desbalance de clases sobre el conjunto de entrenamiento (por ejemplo SMOTE, ADASYN o sobremuestreo aleatorio).
- f) Visualización de la distribución.

3. Reducción de dimensionalidad por PCA:

- a) Aplicar PCA a los datos balanceados.
- b) Cálculo de la varianza acumulada.
- c) Encontrar el número de componentes para el 95 % de varianza.
- d) Gráfico del número de componentes principales y varianza acumulada.

4. Definición de modelos, esquema de trabajo y búsqueda en cuadrícula:

- a) Desarrollar un esquema de funciones (*pipelines*) que integren el preprocesamiento y el clasificador.
- b) Búsqueda en cuadrícula (*grid search*) para encontrar los mejores hiperparámetros.

5. Configuración de modelos y cuadro de hiperparámetros:

- a) **KNN:**
 - vecinos (1, 3, 5, 7, 9).
 - pesos (*weights*: [*'uniform'*, *'distance'*]).
 - distancia (*metric*: [*'euclidean'*, *'manhattan'*]).
- b) **Árbol de decisión:**
 - profundidad ([3, 5, 7, None]).
 - muestras mínimas por división ([2, 5, 10]).
 - criterio ([*'gini'*, *'entropy'*]).
- c) **SVM:**
 - kernel ([*'linear'*, *'rbf'*]).
 - Regularización *C* (0.1, 1, 10).
 - Gamma ([*'scale'*, *'auto'*, 0.01, 0.1]).

6. Entrenamiento, evaluación y comparación de resultados:

- a) Mejores métricas de rendimiento sobre conjunto de prueba por conjunto de datos.
- b) Matriz de confusión de los modelos entrenados con las mejores métricas.
- c) Fronteras de decisión superponiendo datos de entrenamiento y prueba.
- d) Árbol entrenado con los mejores parámetros.
- e) Comparación de exactitud entre modelos.
- f) ¿Qué hiperparámetro fue más relevante por modelo para cada conjunto de datos?

4. Código

4.1. Repositorio

Los notebooks `.ipynb` así como los demás archivos de la práctica se encuentran en el siguiente repositorio de GitHub: <https://github.com/Garp02/Reconocimiento-Patrones/tree/main/P4>

De los cuatro conjuntos propuestos se eligieron dos: **Breast Cancer Wisconsin Diagnostic** y **Heart Disease**. Ambos son problemas de clasificación binaria en el dominio biomédico, pero presentan retos complementarios que permiten contrastar el comportamiento de los tres clasificadores: el primero es prácticamente “ideal” (sin faltantes, con 30 características numéricas y clases bien separadas en el espacio de entrada), mientras que el segundo concentra las dificultades típicas de un conjunto clínico real (faltantes masivos, mezcla de variables continuas y categóricas codificadas, y separación de clases mucho menos limpia).

Como esquema común para los dos conjuntos se siguió el flujo: carga → exploración → preprocesamiento → partición 70/30 estratificada → SMOTE sobre *train* → PCA (*mle*, 95 % de varianza y proyección 2D) → *grid search* con CV de 5 *folds* para KNN, árbol de decisión y SVM → evaluación final sobre el conjunto de prueba. La semilla `random_state = 43` se usó en todos los componentes estocásticos para garantizar reproducibilidad.

4.2. Conjunto de datos: Breast Cancer Wisconsin Diagnostic

Carga y exploración

El conjunto **Breast Cancer Wisconsin Diagnostic** contiene **569 muestras** y **30 características numéricas** obtenidas a partir de imágenes digitalizadas de aspiraciones con aguja fina (FNA) de masas mamarias. Las características se agrupan en tres bloques de diez variables que describen el mismo conjunto de propiedades morfológicas (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal) en tres escalas estadísticas: *mean* (promedio del núcleo celular), *se* (error estándar) y *worst* (peor caso, definido como la media de los tres valores más extremos). La variable objetivo **diagnosis** toma los valores B (benigno, 357 casos) y M (maligno, 212 casos), lo que arroja un *ratio* mayoría/minoría de 1:0.59 —ligeramente desbalanceado, pero lejos del umbral que suele requerir intervención agresiva.

El perfilamiento exploratorio con `ydata_profiling` se ejecutó únicamente sobre las diez variables *mean* para no inflar el tiempo de generación del reporte. La revisión confirmó la **ausencia completa de valores faltantes** en todo el conjunto y verificó que las escalas de las características difieren considerablemente: por ejemplo, `area_worst` ronda valores entre 200 y 4254, mientras que `smoothness_mean` se mueve entre 0,05 y 0,16. Esta diferencia de varios órdenes de magnitud justifica plenamente el escalado posterior.

Detección de *outliers* con IQR

Se aplicó el criterio intercuartílico ($Q_1 - 1,5 \cdot IQR$ y $Q_3 + 1,5 \cdot IQR$) sobre las 30 características numéricas. La variable `area_se` concentra el mayor número de valores extremos (65, el 11,4 %), seguida por `radius_se` y `perimeter_se` (ambas con 38, el 6,7 %). En total, **171 de las 569 filas** contienen al menos un *outlier* bajo IQR, una proporción significativa que en otro contexto podría motivar su eliminación. En este caso no se removieron, por dos razones: muchos valores extremos corresponden a tumores efectivamente agresivos (información biológica legítima, no errores de medición) y, al aplicar después un escalado *z-score*, su impacto sobre los modelos se atenúa.

Los *boxplots* de las Figura 1, 2 y 3 comparan las distribuciones *Benigno* vs *Maligno* para los tres grupos de variables. Se aprecia visualmente que los tumores malignos tienden a producir valores sistemáticamente mayores en casi todas las características *mean* y *worst*, mientras que las variables *se* muestran solapamiento más marcado.




Figura 1: *Boxplots* comparativos del grupo de características *mean* del conjunto Cancer. Escala logarítmica.




Figura 2: *Boxplots* comparativos del grupo de características *se* del conjunto Cancer. Escala logarítmica.




Figura 3: *Boxplots* comparativos del grupo de características *worst* del conjunto Cancer. Escala logarítmica.

Preprocesamiento, partición y SMOTE

Las 30 variables numéricas se estandarizaron con `StandardScaler` y se separaron en 70 % entrenamiento ($n = 398$) y 30 % prueba ($n = 171$) mediante `train_test_split` con `stratify=y` y `random_state=43`. Aunque el desbalance original (0,59) es moderado, se aplicó **SMOTE** sobre el conjunto de entrenamiento por fidelidad al enunciado de la práctica. Esto elevó el número de muestras malignas de 148 a 250, igualando ambas clases y produciendo un conjunto balanceado de 500 muestras (Figura 4).




Figura 4: Distribución de clases en el conjunto de entrenamiento de Cancer, antes y después de aplicar SMOTE.

Reducción de dimensionalidad con PCA

Se compararon tres configuraciones de PCA: estimación automática con *Minka's Maximum Likelihood Estimation* (`n_components = 'mle'`), umbral de varianza acumulada del 95 % y proyección a 2 componentes para visualización. El método MLE seleccionó **29 componentes** (esencialmente conserva todo el espacio original, lo que indica que prácticamente todas las direcciones aportan información estadísticamente significativa); el umbral del 95 % se alcanza con tan solo **10 componentes**; y las dos primeras componentes capturan ya una fracción considerable de la varianza (Figura 5).




Figura 5: Varianza acumulada para PCA con *Minka's MLE* sobre Cancer. Los 29 componentes seleccionados absorben casi la totalidad de la varianza.




Figura 6: Varianza acumulada al fijar PCA con 95 %: bastan 10 componentes para superar el umbral.

La proyección 2D (Figura 7) muestra que las clases *B* y *M* son **linealmente separables casi por completo** ya en las dos primeras componentes principales. Este hecho resulta clave para entender el alto desempeño que más adelante obtienen los tres clasificadores: el problema es “fácil” geoméricamente.




Figura 7: Proyección 2D de PCA sobre el conjunto de entrenamiento de Cancer. La separación entre clases es muy clara.

Pipelines, búsqueda en cuadrícula y resultados

Se construyeron tres Pipeline con un único paso de clasificador (KNN, árbol y SVM), todos entrenados sobre los datos balanceados con SMOTE. La búsqueda en cuadrícula se realizó con `GridSearchCV`, CV estratificada de 5 *folds*, métrica *accuracy* y `n_jobs = -1`. Los hiperparámetros explorados son los pedidos por el enunciado (Sección 3.5). Los mejores resultados se resumen en la Tabla 1.

Modelo	Mejores hiperparámetros	CV Acc.	Test Acc.	Recall	F1
KNN	$k = 9$, <i>distance</i> , euclidean	0,9860	0,9532	0,9688	0,9394
Árbol de Decisión	gini, depth= 5, split= 5	0,9500	0,9474	0,9375	0,9302
SVM	lineal, $C = 1$, γ =scale	0,9740	0,9766	0,9844	0,9692

Cuadro 1: Resultados de los tres clasificadores sobre Cancer. El SVM lineal obtiene la mejor exactitud en prueba.

La Figura 8 muestra las matrices de confusión sobre el conjunto de prueba. El SVM cae en apenas 4 errores de 171 muestras: 3 falsos positivos y 1 falso negativo. KNN comete 8 errores (2 FP, 6 FN) y el árbol 9 (4 FP, 5 FN). En un contexto clínico real, el *recall* sobre la clase maligna (sensibilidad para no perder casos positivos) es la métrica más relevante; bajo ese criterio el SVM también domina con 0,9844.




Figura 8: Matrices de confusión sobre el conjunto de prueba de Cancer para los tres modelos.

Fronteras de decisión en el espacio PCA 2D

Para inspeccionar visualmente las fronteras, los tres clasificadores se re-entrenaron sobre las dos primeras componentes principales calculadas sobre el conjunto balanceado. Es importante señalar que estos modelos 2D no son los que producen las métricas reportadas; sirven exclusivamente como herramienta de visualización. La Figura 9 muestra los tres modelos: el KNN produce una frontera *fractal* con regiones aisladas (esperable por su naturaleza local), el árbol genera fronteras estrictamente ortogonales a los ejes (consecuencia directa de las divisiones *feature-by-feature*) y el SVM lineal traza una recta limpia que separa las clases con un margen amplio.




Figura 9: Fronteras de decisión en PCA 2D para Cancer: KNN (arriba izquierda), árbol (arriba derecha) y SVM lineal (abajo).

Árbol de decisión

La Figura 10 presenta el árbol entrenado con los mejores hiperparámetros (gini, profundidad 5, división mínima 5). El nodo raíz divide por `concave_points_worst`, una de las características que el perfilamiento ya señalaba como fuertemente discriminativa. Subsiguientes divisiones usan `texture_worst`, `radius_worst` y `area_se`, lo que es coherente con el hecho biomédico de que los tumores malignos

tienden a tener bordes más irregulares y mayor tamaño.

Árbol de decisión — Mejores hiperparámetros: {'clf_criterion': 'gini', 'clf_max_depth': 5, 'clf_min_samples_split': 5}




Figura 10: Árbol de decisión entrenado sobre Cancer con los mejores hiperparámetros.

Comparación e hiperparámetro más relevante

La Figura 11 contrasta exactitud en CV vs exactitud en prueba. Llama la atención que KNN, que en CV obtuvo el mejor resultado (0,9860), cae en prueba a 0,9532: es la mayor *brecha* entre los tres modelos. Esto sugiere un cierto sobreajuste del KNN al conjunto balanceado por SMOTE (los puntos sintéticos son interpolaciones que el algoritmo de vecinos memoriza sin esfuerzo). El SVM, en cambio, generaliza mejor: pasa de 0,9740 en CV a 0,9766 en prueba —una ligera mejora atribuible a la varianza muestral—.




Figura 11: Comparación de exactitud CV vs Test para los tres modelos sobre Cancer.

Para identificar el hiperparámetro más relevante de cada modelo se calculó, sobre los resultados del `cv_results_`, el rango (máximo menos mínimo) del *accuracy* promedio al fijar cada hiperparámetro en sus posibles valores. Los resultados se muestran en la Tabla 2.

Modelo	Hiperparámetro más relevante	Δ accuracy
KNN	<code>weights</code>	0,0110
Árbol de Decisión	<code>criterion</code>	0,0112
SVM	<code>C</code>	0,0152

Cuadro 2: Hiperparámetro más sensible por modelo sobre Cancer.

Las diferencias absolutas son pequeñas (de orden 10^{-2}) porque el problema es tan separable que todos los modelos alcanzan ya valores muy altos. Aun así, los resultados son coherentes con la teoría: en KNN el peso de los vecinos importa más que el número exacto cuando k es moderado; en árboles el criterio *gini/entropy* fija el sesgo inductivo del crecimiento; y en SVM la regularización C controla directamente la tolerancia a errores y por tanto la geometría del margen.

4.3. Conjunto de datos: Heart Disease

Carga, combinación de fuentes y reformulación binaria

El conjunto **Heart Disease** del UCI Machine Learning Repository está dividido en cuatro archivos correspondientes a los hospitales que recolectaron los datos: **cleveland** (303 instancias), **hungarian** (294), **switzerland** (123) y **va** (200). Para esta práctica se concatenaron los cuatro en un único **DataFrame** de **920 instancias** y 14 columnas, añadiendo una variable auxiliar **origen** para mantener la trazabilidad. La variable objetivo original **num** toma valores enteros entre 0 y 4 (donde 0 es ausencia de enfermedad y 1–4 distintos grados de afectación). Por consistencia con la literatura clásica del conjunto y para simplificar el problema a una clasificación binaria, se reformuló como **target = num > 0**, obteniendo 411 sanos y 509 enfermos. El desbalance es leve (*ratio* 1,24).

Análisis de valores faltantes: el reto principal

A diferencia del conjunto Cancer, Heart Disease presenta una proporción muy alta de valores faltantes, fuertemente concentrada por archivo de origen. La Tabla 3 desglosa los porcentajes globales y por hospital.

Variable	Global (%)	Hungarian (%)	Switzerland (%)	VA (%)
ca	66,4	99,0	95,9	99,0
thal	52,8	90,5	42,3	83,0
slope	33,6	64,6	13,8	51,0
fbs	9,8	2,7	61,0	3,5
oldpeak	6,7	0,0	4,9	28,0
trestbps	6,4	0,3	1,6	28,0
thalach	6,0	0,3	0,8	26,5
exang	6,0	0,3	0,8	26,5
chol	3,3	7,8	0,0	3,5

Cuadro 3: Distribución de valores faltantes en Heart Disease, global y por archivo de origen.

El patrón es revelador: **ca**, **thal** y **slope** están prácticamente ausentes fuera de Cleveland, lo que sugiere que esos hospitales simplemente no registraron esas pruebas. Dado que descartarlas completas sería renunciar a información valiosa para los casos donde sí están disponibles, se optó por **imputar**: mediana para las variables continuas (**age**, **trestbps**, **chol**, **thalach**, **oldpeak**, **ca**) y moda (*most_frequent*) para las codificadas categóricamente (**sex**, **cp**, **fbs**, **restecg**, **exang**, **slope**, **thal**). Esta decisión introduce un sesgo controlado —la mediana/moda no preserva la varianza condicional de las relaciones entre variables— pero es defendible dada la escala del problema.

Variables continuas vs categóricas codificadas

Heart Disease contiene 13 predictoras, de las cuales 6 son continuas y 7 son categóricas codificadas como números (binarias u ordinales). La Figura 12 muestra la distribución del objetivo binario y la Figura 13 compara las distribuciones de las variables continuas para los grupos *Sano* vs *Enfermo*.




Figura 12: Distribución de clases tras la reformulación binaria de Heart Disease.




Figura 13: *Boxplots* comparativos de las variables continuas de Heart Disease, separados por clase.

Aunque varias variables muestran sesgos consistentes con el diagnóstico —por ejemplo, los pacien-

tes enfermos tienden a tener `thalach` (frecuencia cardíaca máxima alcanzada) más baja y `oldpeak` (depresión del ST inducida) más alta—, el solapamiento entre clases es considerable. La detección de *outliers* con IQR identificó 330 filas con al menos un valor extremo, principalmente en `chol` (185 *outliers*, 20,1 %) y `ca` (128, 13,9 %). Estos valores se conservaron porque corresponden a casos clínicamente reales (colesterol extremadamente alto, múltiples vasos afectados) y eliminarlos sesgaría el modelo precisamente en la población más enferma.

Preprocesamiento, partición y SMOTE

A diferencia del notebook de Cancer, aquí el escalado se ajustó *después* del `train_test_split` para evitar fuga de información del conjunto de prueba. La partición 70/30 produjo 644 muestras de entrenamiento y 276 de prueba. SMOTE se aplicó solo sobre *train*, llevando los conteos de 288 sanos / 356 enfermos a 356/356 (Figura 14).




Figura 14: Distribución de clases en *train* de Heart Disease antes y después de SMOTE.

Reducción de dimensionalidad

PCA con *Minka's MLE* seleccionó **11 componentes** y el umbral del 95 % se alcanzó con **12** —es decir, las 13 variables originales son prácticamente todas informativas y existe muy poca redundancia— (Figuras 15 y 16). Este es un comportamiento marcadamente distinto del observado en Cancer, donde el 95 % se alcanzaba con tan solo 10 de las 30 originales: en Heart Disease cada predictora aporta información sustancial y la compresión es modesta.




Figura 15: Varianza acumulada con PCA *MLE* sobre Heart Disease (11 componentes seleccionados).




Figura 16: Varianza acumulada al fijar PCA con 95 %: se requieren 12 componentes.

La proyección 2D de la Figura 17 evidencia el contraste con Cancer: aquí las dos clases se solapan ampliamente. Esta es la principal razón por la que las exactitudes de los modelos sobre Heart Disease ($\sim 0,84$) son notablemente menores que sobre Cancer ($\sim 0,97$): el problema es intrínsecamente más difícil.




Figura 17: Proyección 2D de PCA sobre Heart Disease. El solapamiento entre Sano y Enfermo es considerable.

Búsqueda en cuadrícula y resultados

Se aplicó el mismo esquema de `GridSearchCV` con CV de 5 *folds*. Los mejores resultados aparecen en la Tabla 4.

Modelo	Mejores hiperparámetros	CV Acc.	Test Acc.	Recall	F1
KNN	$k = 7$, <i>distance</i> , <i>manhattan</i>	0,8217	0,8442	0,8627	0,8599
Árbol de Decisión	<i>gini</i> , <i>depth</i> = 5, <i>split</i> = 5	0,7880	0,7536	0,7320	0,7671
SVM	RBF, $C = 1$, γ =scale	0,8400	0,8225	0,8693	0,8444

Cuadro 4: Resultados de los tres clasificadores sobre Heart Disease.

A diferencia de Cancer, aquí gana **KNN** en exactitud sobre el conjunto de prueba (0,8442), aunque el SVM con kernel RBF lo supera ligeramente en *recall* (0,8693 vs 0,8627). El árbol queda claramente por debajo, lo que ya anticipaba el bajo desempeño esperable de un único árbol cuando las clases están entrelazadas y las divisiones ortogonales no alcanzan a capturar la frontera real. La Figura 18 muestra las matrices de confusión.




Figura 18: Matrices de confusión sobre el conjunto de prueba de Heart Disease.

Fronteras de decisión en PCA 2D

La Figura 19 muestra las fronteras de los tres modelos entrenados sobre las dos primeras componentes principales. Comparadas con las de Cancer, las fronteras son mucho menos definidas: los puntos de ambas clases se entremezclan y obligan a cada algoritmo a producir regiones complejas y poco confiables fuera de las zonas más densamente pobladas. Esta visualización ilustra por qué la exactitud no puede ser tan alta como en Cancer y por qué el árbol —que carece de la flexibilidad geométrica del SVM-RBF y de la localidad del KNN— es el que más sufre.




Figura 19: Fronteras de decisión en PCA 2D para Heart Disease: KNN (arriba izquierda), árbol (arriba derecha) y SVM-RBF (abajo).

Árbol de decisión

El árbol entrenado con los mejores hiperparámetros se presenta en la Figura 20. El nodo raíz divide por `cp` (tipo de dolor torácico), lo cual es clínicamente esperable porque es uno de los predictores más informativos del riesgo cardíaco. Subsiguientes divisiones involucran `thal`, `ca` y `oldpeak`, todas variables ya identificadas en la literatura como fuertemente asociadas a la presencia de enfermedad coronaria.

Árbol de decisión — Mejores hiperparámetros: {'clf__criterion': 'gini', 'clf__max_depth': 5, 'clf__min_samples_split': 5}




Figura 20: Árbol de decisión entrenado sobre Heart Disease.

Comparación e hiperparámetro más relevante

La Figura 21 muestra que la *brecha* entre CV y prueba es modesta para los tres modelos ($\sim 0,02$ en valor absoluto), lo que sugiere que no hay sobreajuste significativo. El patrón de hiperparámetros más relevantes (Tabla 5) cambia respecto a Cancer:




Figura 21: Comparación de exactitud CV vs Test sobre Heart Disease.

Modelo	Hiperparámetro más relevante	Δ accuracy
KNN	<code>n_neighbors</code>	0,0249
Árbol de Decisión	<code>max_depth</code>	0,0161
SVM	<code>C</code>	0,0096

Cuadro 5: Hiperparámetro más sensible por modelo sobre Heart Disease.

En Heart Disease el `n_neighbors` es el hiperparámetro más relevante para KNN ($\Delta = 0,0249$, más del doble que en Cancer), lo cual tiene sentido geométrico: cuando las clases se solapan, el tamaño del vecindario determina si el modelo memoriza ruido (k bajo) o suaviza demasiado (k alto). Para el árbol, la profundidad máxima toma el protagonismo (frente al criterio en Cancer): con clases más mezcladas, permitir más o menos divisiones cambia significativamente la complejidad del modelo. El SVM mantiene a C como hiperparámetro dominante en ambos conjuntos, confirmando su rol estructural en la geometría del margen.

4.4. Comparación cruzada entre conjuntos

La Tabla 6 sintetiza los mejores resultados de los tres clasificadores sobre los dos conjuntos.

Modelo	Cancer Test Acc.	Cancer Test F1	Heart Test Acc.	Heart Test F1
KNN	0,9532	0,9394	0,8442	0,8599
Árbol de Decisión	0,9474	0,9302	0,7536	0,7671
SVM	0,9766	0,9692	0,8225	0,8444

Cuadro 6: Comparación cruzada de los mejores modelos en los dos conjuntos de datos.

Tres lecturas se desprenden de la comparación:

1. **La dificultad del problema gobierna el techo, no el modelo.** La caída de $\sim 0,13$ puntos en exactitud al pasar de Cancer a Heart Disease es transversal a los tres clasificadores y refleja la separabilidad inherente al espacio de características. En Cancer las dos primeras componentes principales casi separan linealmente las clases; en Heart Disease incluso 12 componentes dejan zonas de mezcla considerables.
2. **El SVM domina cuando hay margen claro.** En Cancer, donde las clases admiten una separación casi lineal en alta dimensión, el SVM lineal ofrece el mejor compromiso entre simplicidad y desempeño. En Heart Disease, donde la frontera es más compleja y la dimensión efectiva es prácticamente la original, el SVM con kernel RBF mantiene la cabeza pero pierde el liderato frente al KNN, que se beneficia de las relaciones locales entre vecinos tras el sobremuestreo de SMOTE.
3. **El árbol es siempre la opción menos competitiva.** Un único árbol carece de la flexibilidad de los *ensembles* (Random Forest, Gradient Boosting) y compite en desventaja incluso cuando los datos son fáciles. Su valor real está en la interpretabilidad —el camino raíz-hoja es una regla diagnóstica legible— más que en la exactitud bruta.

5. Conclusiones

Comparando tres clasificadores supervisados —KNN, árbol de decisión y SVM— sobre dos conjuntos de datos biomédicos de complejidad muy distinta, se contrastaron sus principios teóricos con el desempeño observado en la práctica.

El conjunto **Cancer Wisconsin** resultó ser un problema casi linealmente separable: incluso en la proyección 2D de PCA las clases benigna y maligna quedan claramente delimitadas, y los tres modelos alcanzan exactitudes superiores a 0,94 sobre el conjunto de prueba. El SVM lineal fue el más preciso (0,9766), capturando la frontera con un margen amplio y un solo falso negativo de 64 casos malignos.

Heart Disease, en cambio, planteó un escenario mucho más realista y exigente: 66 % de faltantes en *ca*, 53 % en *thal*, 13 predictoras heterogéneas (continuas y categóricas codificadas) y un solapamiento marcado entre sanos y enfermos en el espacio reducido. Aquí ningún modelo superó el 0,85 de

exactitud y el ranking se invirtió: KNN quedó al frente (0,8442), seguido del SVM-RBF (0,8225) y muy por debajo el árbol de decisión (0,7536).

PCA cumplió papeles distintos en cada conjunto. En Cancer el método MLE seleccionó 29 de 30 componentes, indicando que las características son prácticamente todas independientes y poco redundantes; el umbral del 95 % se logra con 10 componentes y la separación entre clases es visible ya en PC1-PC2. En Heart Disease, MLE escogió 11 de 13 componentes y el 95 % se alcanza con 12: hay incluso menos redundancia, y la dificultad del problema no se debe a la dimensionalidad sino a la geometría intrínseca de las clases.

La aplicación de SMOTE, aunque pedida por el enunciado, era prescindible en ambos casos por el desbalance moderado de partida (0,59 y 1,24). Su efecto colateral fue introducir ruido sintético del que el KNN se benefició en Heart Disease (al multiplicar la densidad local de la clase minoritaria) y posiblemente perjudicó al KNN en Cancer (memorización excesiva, evidenciada por la brecha CV-test de 0,033).

El análisis de hiperparámetros mostró que *C* es el **parámetro más sensible del SVM** en ambos conjuntos, confirmando su rol estructural en la geometría del margen. Para KNN, **weights** dominó en el caso fácil (Cancer) y **n_neighbors** en el difícil (Heart Disease): cuando las clases están bien separadas la métrica de ponderación importa poco; cuando se solapan, el tamaño del vecindario decide si el modelo memoriza ruido o suaviza demasiado. El árbol cambió de **criterion** a **max_depth** entre conjuntos, lo que es coherente con su naturaleza recursiva: en problemas fáciles cualquier criterio converge a un árbol similar, pero en problemas difíciles la profundidad es lo único que separa el sobreajuste del subajuste.

Finalmente, la diferencia de desempeño entre Cancer y Heart Disease, mucho mayor que cualquier diferencia entre modelos dentro de un mismo conjunto, deja una conclusión transversal: **la dificultad intrínseca del problema gobierna el techo de exactitud, mientras que la elección del clasificador refina sólo los últimos puntos porcentuales**. En problemas clínicos como este, invertir en calidad de datos, ingeniería de características y manejo cuidadoso de los faltantes rinde tanto o más que elegir el algoritmo de última generación.



6. Referencias

- Tolstikhin, Ilya O., et al. *Mlp-mixer: An all-mlp architecture for vision*. Advances in neural information processing systems 34 (2021): 24261–24272.
- Wu, Baoyuan, et al. *Defenses in adversarial machine learning: A survey*. arXiv preprint arXiv:2312.08890 (2023).
- Liu, Xiao, et al. *Self-supervised learning: Generative or contrastive*. IEEE transactions on knowledge and data engineering 35.1 (2021): 857–876.
- Goodfellow, Ian. *Deep learning*. MIT Press, 2016.
- Murphy, Kevin P. *Machine learning: a probabilistic perspective*. MIT Press, 2012.
- Hastie, T., Tibshirani, R., & Friedman, J. *The Elements of Statistical Learning*. 2nd ed. Springer, 2009.
- Pedregosa, F., et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research 12 (2011): 2825–2830.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research 16 (2002): 321–357.
- Minka, T. *Automatic choice of dimensionality for PCA*. Advances in Neural Information Processing Systems 13 (2000).
- Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5DW2B>.
- Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). Heart Disease [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C52P4X>.