



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y
Sistemas

Práctica 5 - Agrupamiento y clasificación

PRESENTA

Munive Ramírez Ibrahim

PROFESORA

Dra. María Elena Martínez Pérez

ASIGNATURA

Reconocimiento de Patrones

1. Objetivos

Esta práctica introduce el modelo de bolsa de palabras o *Bag of Visual Words* (BoVW) para la clasificación de imágenes. El flujo de trabajo incluye:

- Extraer descriptores SIFT de un conjunto de imágenes.
- Construir un vocabulario visual aplicando k-means.
- Representar cada imagen mediante un histograma normalizado de palabras visuales.
- Clasificar las imágenes.
- Evaluar el modelo con exactitud y matriz de confusión.
- Experimentar con distintos parámetros (número de palabras, tipo de clasificador, etc.).

2. Introducción

El reconocimiento de patrones en imágenes es un área fundamental de la visión por computadora. Uno de los enfoques más populares para la clasificación de escenas u objetos es el modelo *Bag of Words* (BoVW), inspirado en el procesamiento de texto. En lugar de palabras, se utilizan *palabras visuales* obtenidas a partir de descriptores locales de las imágenes. Este método es robusto frente a variaciones de escala, rotación e iluminación parcial.

2.1. Bolsa de palabras (Bag of Words)

El modelo (BoW) es ampliamente utilizado en procesamiento de lenguaje natural. Consiste en representar un documento como un vector de frecuencias de palabras de un vocabulario predefinido, ignorando el orden de las palabras pero preservando la información semántica relevante. Por ejemplo, si el vocabulario es $\{\text{perro}, \text{gato}, \text{ratón}\}$, un documento con las palabras “gato gato perro” se representa como $[1, 2, 0]$.

La clave del éxito de BoW es que palabras similares tienden a aparecer en contextos similares, y dos documentos con distribuciones de palabras parecidas probablemente tratan sobre el mismo tema.

2.2. Traslación al dominio visual: palabras visuales

De manera análoga, en el enfoque BoW se considera que una imagen es un “documento” compuesto por “palabras visuales”. Estas palabras no son objetos completos, sino **parches locales de la imagen**

que han sido cuantificados en un vocabulario. El proceso típico consta de tres fases:

1. **Extracción de descriptores locales:** Se detectan regiones de interés (por ejemplo, esquinas, bordes, texturas) y se calcula un descriptor numérico que resume la apariencia de cada región. Uno de los descriptores más potentes y ampliamente usados es **SIFT** (Scale-Invariant Feature Transform), desarrollado por David Lowe en 2004. SIFT es invariante a rotación y escala parcial, y robusto a cambios de iluminación. Cada descriptor es un vector de 128 números reales.
2. **Construcción del vocabulario visual:** Se toman todos los descriptores extraídos de un conjunto de entrenamiento y se agrupan mediante un algoritmo de clustering, típicamente *k-means*. Cada centroide resultante define una “palabra visual”. El número k de palabras es un hiperparámetro crítico: valores pequeños producen palabras muy generales, valores grandes producen palabras muy específicas (riesgo de sobreajuste).
3. **Representación de la imagen como histograma:** Para una imagen nueva, se extraen sus descriptores SIFT y cada uno se asigna a la palabra visual más cercana (en distancia euclídea). Se cuenta cuántas veces aparece cada palabra y se normaliza el histograma para que sume 1. Este histograma es el vector de características que se usará para la clasificación.

2.3. Ventajas del modelo BoW

- **Invariancia parcial:** Al depender de descriptores locales invariantes (SIFT), el modelo tolera cambios de escala, rotación y traslación de los objetos.
- **Compacidad:** Una imagen se reduce de miles de píxeles a un histograma de dimensión k (típicamente entre 100 y 1000), lo que facilita el entrenamiento de clasificadores.
- **Simplicidad conceptual:** La analogía con el texto es fácil de entender y extender.
- **Buen rendimiento:** En su época, BoW logró resultados competitivos en benchmarks como Caltech-101.

2.4. Clasificador empleado: Máquina de Vectores Soporte (SVM)

Una vez que tenemos los histogramas, necesitamos un clasificador que aprenda a separar las distintas categorías. Utilizaremos una **Máquina de Vectores Soporte** con kernel lineal. El SVM busca el hiperplano que maximiza el margen entre las clases. Es especialmente eficaz cuando el número de características es moderado (nuestro k) y hay un número suficiente de ejemplos. La elección del kernel lineal evita la complejidad de kernels no lineales y suele funcionar bien para histogramas normalizados.

2.5. Métricas de evaluación

Para medir el rendimiento del clasificador usaremos dos herramientas estándar:

- **Accuracy** (exactitud): Proporción de aciertos global. Se define como $\frac{TP+TN}{TP+TN+FP+FN}$, aunque en clasificación multiclase se calcula como el número de predicciones correctas dividido entre el total. Es una medida intuitiva pero puede ser engañosa si las clases están desbalanceadas.
- **Matriz de confusión**: Una tabla de tamaño $C \times C$ (donde C es el número de clases) donde la entrada (i, j) indica cuántas muestras de la clase real i fueron clasificadas como clase j . Permite identificar confusiones específicas: por ejemplo, que muchos aviones sean etiquetados como pájaros, o que los coches y las motos se confundan entre sí.

3. Desarrollo

Se implementó el modelo *Bag of Visual Words* (BoVW) sobre el conjunto de datos **CIFAR-10**, aplicando el flujo completo de extracción de características, construcción del vocabulario visual, clasificación y evaluación comparativa.

3.1. Conjunto de datos

Se utilizó CIFAR-10 descargado mediante `torchvision`. Todas las imágenes fueron redimensionadas a 128×128 píxeles usando interpolación Lanczos. Para la extracción inicial del vocabulario visual se empleó únicamente la clase `airplane` (5 000 imágenes), verificando el flujo de trabajo con una sola categoría. Para los experimentos de clasificación se tomó una submuestra balanceada de **500 imágenes por clase** (5 000 en total para las 10 categorías), garantizando que el problema de clasificación multiclase fuera manejable en tiempo de cómputo.

3.2. Extracción de descriptores SIFT

Se empleó el detector-descriptor **SIFT** (Scale-Invariant Feature Transform) de OpenCV. Cada imagen se convirtió a escala de grises antes de aplicar `detectAndCompute`. El resultado fue un conjunto de vectores de 128 dimensiones, uno por cada punto clave detectado.

- Imágenes de `airplane` únicamente: **178 172 descriptores** en total.
- 10 clases (500 imágenes por clase): **245 210 descriptores** en total.

Las imágenes con cero keypoints (muy pocas en CIFAR-10 por su baja resolución original) recibieron un descriptor nulo para no quedar excluidas del proceso.

3.3. Construcción del vocabulario visual (k-means)

Todos los descriptores extraídos del conjunto de entrenamiento se concatenaron en una única matriz y se les aplicó **k-means** con $k = 100$ como valor base ($n_init = 10$, $random_state = 42$). Cada centroide obtenido define una “palabra visual”; el conjunto de centroides constituye el **vocabulario visual**.

3.4. Representación BoW: histogramas normalizados

Para cada imagen se asignó cada uno de sus descriptores SIFT al centroide más cercano del vocabulario (cuantización vectorial). Se acumuló un histograma de k entradas que contabiliza cuántas veces aparece cada palabra visual. El histograma se normalizó con norma L1 (dividiendo entre la suma total), de modo que cada vector de características sumara exactamente 1 y fuera comparable entre imágenes con distinto número de keypoints.

3.5. División entrenamiento / prueba

El conjunto de 5 000 histogramas se dividió en proporción **80/20** con estratificación por clase (`stratify`):

- **Entrenamiento:** 4 000 muestras (400 por clase).
- **Prueba:** 1 000 muestras (100 por clase).

3.6. Clasificador SVM con búsqueda de hiperparámetros

Se entrenó una **SVM lineal** (`SVC(kernel='linear')`) usando `GridSearchCV` con validación cruzada de 3 particiones sobre el conjunto de entrenamiento. Se exploró la cuadrícula $C \in \{0,01, 0,1, 1, 10\}$.

El mejor parámetro encontrado fue $C = 10$, con una exactitud media en validación cruzada de 0,2828 (28,28 %). La exactitud sobre el conjunto de prueba fue **0,2810 (28,10 %)**.

La exactitud es modesta pero coherente con las limitaciones del método BoW sobre CIFAR-10: las imágenes son de baja resolución (32×32 originales, redimensionadas a 128×128) y SIFT extrae pocos descriptores discriminativos por imagen.

3.7. Variación del vocabulario visual ($k = 50, 200, 500$)

Para estudiar el efecto del tamaño del vocabulario se reentrenó el clasificador SVM lineal (con $C = 1,0$ fijo) para tres valores adicionales de k . Los resultados muestran una **tendencia decreciente** conforme aumenta k a partir de 50:

k	Exactitud (prueba)
50	25,70 %
100	28,10 %
200	24,20 %
500	22,00 %

El valor $k = 100$ resultó ser el mejor entre los evaluados: vocabularios menores son demasiado gruesos para distinguir las 10 clases, mientras que vocabularios mayores producen histogramas demasiado dispersos y sensibles al ruido con solo 500 imágenes por clase.

3.8. Comparación con Random Forest

Se substituyó la SVM por un **Random Forest** usando **GridSearchCV** con 3 particiones y cuadrícula $\{n_estimators\} \times \{max_depth\} = \{100, 200\} \times \{None, 20\}$. Los mejores hiperparámetros fueron $n_estimators = 200$ y $max_depth = None$ (sin límite de profundidad), obteniendo una exactitud de **0,2730** (27,30 %), ligeramente inferior a la SVM lineal (28,10 %).

3.9. Validación cruzada de 5 particiones

Para obtener estimaciones más robustas del rendimiento se realizó una validación cruzada con **5 particiones** (**cross_val_score**) sobre el conjunto completo de 5 000 histogramas, tanto para SVM ($C = 10$) como para Random Forest ($n_estimators = 200$, $max_depth = None$):

Clasificador	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Media $\pm$ Desv.
SVM lineal	0,2750	0,2940	0,2610	0,3070	0,2840	$0,2842 \pm 0,0157$
Random Forest	0,2700	0,2850	0,3010	0,2690	0,3070	$0,2864 \pm 0,0156$

Ambos clasificadores presentan rendimientos estadísticamente equivalentes: las medias difieren en menos de 0,003 y las desviaciones estándar son prácticamente idénticas ($\approx 0,016$), lo que indica que la variabilidad entre particiones es la misma para ambos modelos.

4. Código

4.1. Repositorio

Los notebooks `.ipynb` así como los demás archivos de la práctica se encuentran en el siguiente repositorio de GitHub: <https://github.com/Garp02/Reconocimiento-Patrones/tree/main/P5>

4.2. Resultados de la extracción de datos

Al cargar el conjunto CIFAR-10 y filtrar la clase `airplane` se obtuvieron **5000 imágenes**, cada una redimensionada a 128×128 píxeles. Un lote de 32 imágenes tiene forma $(32, 3, 128, 128)$.

Parámetro	Valor
Total imágenes (<code>airplane</code>)	5 000
Imágenes por clase (10 clases)	500
Resolución de entrada	128×128 px
Total descriptores SIFT (<code>airplane</code>)	178172
Total descriptores SIFT (10 clases)	245210
Dimensión de cada descriptor	128

4.3. Vocabulario visual y histogramas

Con $k = 100$ palabras visuales, cada imagen queda representada como un histograma de 100 entradas normalizado con norma L1. La matriz de histogramas para el experimento de 10 clases tiene dimensiones 5000×100 .

4.4. División entrenamiento / prueba

Conjunto	Muestras	Forma
Entrenamiento	4000	$(4000, 100)$
Prueba	1000	$(1000, 100)$

4.5. Grid Search — SVM lineal ($k = 100$)

Se probaron 4 valores de C con validación cruzada de 3 particiones (12 ajustes en total).

C	Exactitud CV (3-fold)
0.01	—
0.1	—
1	—
10	0,2828

Mejor parámetro: $C = 10$. Exactitud sobre el conjunto de prueba: **0,2810** (28,10 %).

4.6. Efecto del tamaño del vocabulario ($k = 50, 200, 500$)

SVM lineal con $C = 1,0$ fijo, misma división 80/20.

k	Exactitud (prueba)	Observación
50	25,70 %	Vocabulario insuficiente
100	28,10 %	Mejor resultado
200	24,20 %	Histogramas más dispersos
500	22,00 %	Alta dispersión, ruido

4.7. Comparación SVM vs Random Forest ($k = 100$)

Clasificador	Mejores hiperparámetros	Exactitud (prueba)
SVM lineal	$C = 10$	28,10 %
Random Forest	$n_estimators = 200, max_depth = \infty$	27,30 %

4.8. Validación cruzada 5-fold

Clasificador	F1	F2	F3	F4	F5	Media	Mediana	Desv.
SVM lineal	0,275	0,294	0,261	0,307	0,284	0,2842	0,2840	0,0157
Random Forest	0,270	0,285	0,301	0,269	0,307	0,2864	0,2850	0,0156

Mínimo y máximo por clasificador:

Clasificador	Mín	Máx
SVM lineal	0,2610	0,3070
Random Forest	0,2690	0,3070

5. Conclusiones

La práctica permitió implementar y evaluar de forma completa el modelo *Bag of Visual Words* sobre el conjunto de datos CIFAR-10. A continuación se presentan las conclusiones principales y las respuestas a las preguntas planteadas.

5.1. Resultados generales

Los clasificadores entrenados alcanzaron una exactitud de alrededor del 28 % sobre 10 clases, lo que representa aproximadamente **2.8 veces la línea base de un clasificador aleatorio** (10 %). Este nivel de rendimiento es esperado dada la naturaleza del problema: CIFAR-10 tiene imágenes de 32×32 píxeles con fondos complejos y alta variabilidad intracase, condiciones desfavorables para SIFT, que extrae pocos descriptores confiables en imágenes de tan baja resolución.

El vocabulario visual óptimo fue $k = 100$: valores menores producen histogramas demasiado gruesos e indistinguibles entre clases, mientras que valores mayores generan representaciones demasiado dispersas para el tamaño del conjunto de entrenamiento (400 imágenes por clase). La SVM lineal ($C = 10$) y el Random Forest ($n_estimators = 200$) obtuvieron rendimientos equivalentes en validación cruzada ($0,2842 \pm 0,016$ vs $0,2864 \pm 0,016$), por lo que ninguno de los dos clasificadores destaca claramente sobre el otro en este escenario.

5.2. Respuestas a las preguntas

¿Por qué es necesario normalizar los histogramas?

La normalización es necesaria porque imágenes distintas producen cantidades distintas de keypoints SIFT: una imagen con muchas texturas puede generar diez veces más descriptores que una imagen con superficies homogéneas. Sin normalizar, el histograma crudo reflejaría la *cantidad* de descriptores más que su *distribución relativa*, lo que perjudicaría al clasificador, que interpretaría magnitudes absolutas en lugar de patrones. Al dividir entre la norma L1 (suma total), cada histograma representa la **proporción** de aparición de cada palabra visual, haciendo comparables imágenes de cualquier complejidad.

¿Qué ocurre si k es demasiado pequeño? ¿Y si es demasiado grande?

- **k pequeño:** El vocabulario es poco expresivo. Descriptores con apariencia visual muy diferente quedan asignados al mismo centroide (cuantización gruesa), por lo que los histogramas de clases distintas resultan indistinguibles. El clasificador pierde capacidad discriminativa (subajuste del vocabulario). En los experimentos, $k = 50$ redujo la exactitud a 25,70 %.
- **k grande:** El vocabulario es demasiado fino. Los histogramas se vuelven muy dispersos: la mayor parte de las entradas son cero y unas pocas tienen valores minúsculos. Esto hace que el clasificador sea sensible al ruido y tienda al sobreajuste. Además, el costo computacional de k-means y de la asignación de palabras crece de forma significativa. En los experimentos, $k = 500$ redujo la exactitud al 22,00 % con el mismo tamaño de conjunto de entrenamiento.

El valor óptimo se encuentra en un punto intermedio que puede determinarse mediante validación cruzada.

¿Podría utilizarse este método para detección de objetos en lugar de clasificación?

El BoW estándar descarta la **información espacial** de los descriptores: la imagen se resume como un histograma de frecuencias sin importar la posición de las palabras visuales. Esto lo hace apropiado para *clasificación de categorías*, pero insuficiente para *detección de objetos*, donde es esencial conocer la **localización y la extensión** del objeto dentro de la imagen.

Existen extensiones que incorporan geometría, como el *Spatial Pyramid Matching* (SPM), que divide la imagen en regiones y calcula histogramas locales preservando información espacial parcial. Sin embargo, los detectores modernos basados en redes convolucionales profundas (Faster R-CNN, YOLO, DETR) superan ampliamente a BoW en detección al aprender representaciones conjuntas de apariencia y posición.

5.3. Conclusión final

El modelo BoVW constituye una aproximación clásica y conceptualmente elegante para la clasificación de imágenes. Su principal ventaja es la simplicidad y la interpretabilidad: el proceso de extracción, cuantización y clasificación es transparente y controlable. Sus principales limitaciones son la pérdida de información espacial, la sensibilidad a la resolución de las imágenes y la dificultad para escalar a grandes vocabularios sin un conjunto de entrenamiento proporcionalmente mayor. En contextos de alta resolución y con descriptores más ricos, o combinado con extensiones espaciales, BoVW puede alcanzar rendimientos competitivos. Para problemas modernos de visión por computadora, los métodos basados en aprendizaje profundo han superado consistentemente a BoVW.

6. Referencias

- D. G. Lowe, "Distinctive image features from scale-invariant keypoints", IJCV 2004.
- G. Csurka et al., "Visual categorization with bags of keypoints", ECCV 2004.
- Scikit-learn documentation: <https://scikit-learn.org>
- OpenCV Python tutorials: <https://docs.opencv.org>